

# 빅데이터 분석 프로그래밍

## Introduction

2021-Spring 서중원

# 강사소개




서중원

<https://github.com/thejungwon>

- 경력
  - 연세대 정보대학원 강사 (2019-)
  - IT교육 및 컨설팅 업체 CodeVinci 대표
  - 스타트업 BeBridge CTO
  - 스타트업 코스폴 Lead Developer
- 학력
  - University of Stavanger, 컴퓨터과학 석사
  - 연세대학교 컴퓨터과학 학사
- 기타
  - AWS (Seoul), Equinor (Norway) 인턴
  - NASA-Yonsei 큐브위성 프로젝트 개발자


# Big Data and Machine Learning





# 빅데이터의 시대는 끝난건가?

Figure 1. Hype Cycle for Emerging Technologies, 2015




**"Big data...has become prevalent in our lives"**  
**-- Betsy Burton, Gartner Analyst**

# 주 산업이 급격하게 변하고 있다.

## The Age of the Tech Giants

Companies with the world's largest market capitalizations in 2005 and 2020 (in billion U.S. dollars)\*



\* As of March 31, 2005 and August 20, 2020.  
Sources: Financial Times, Yahoo! Finance



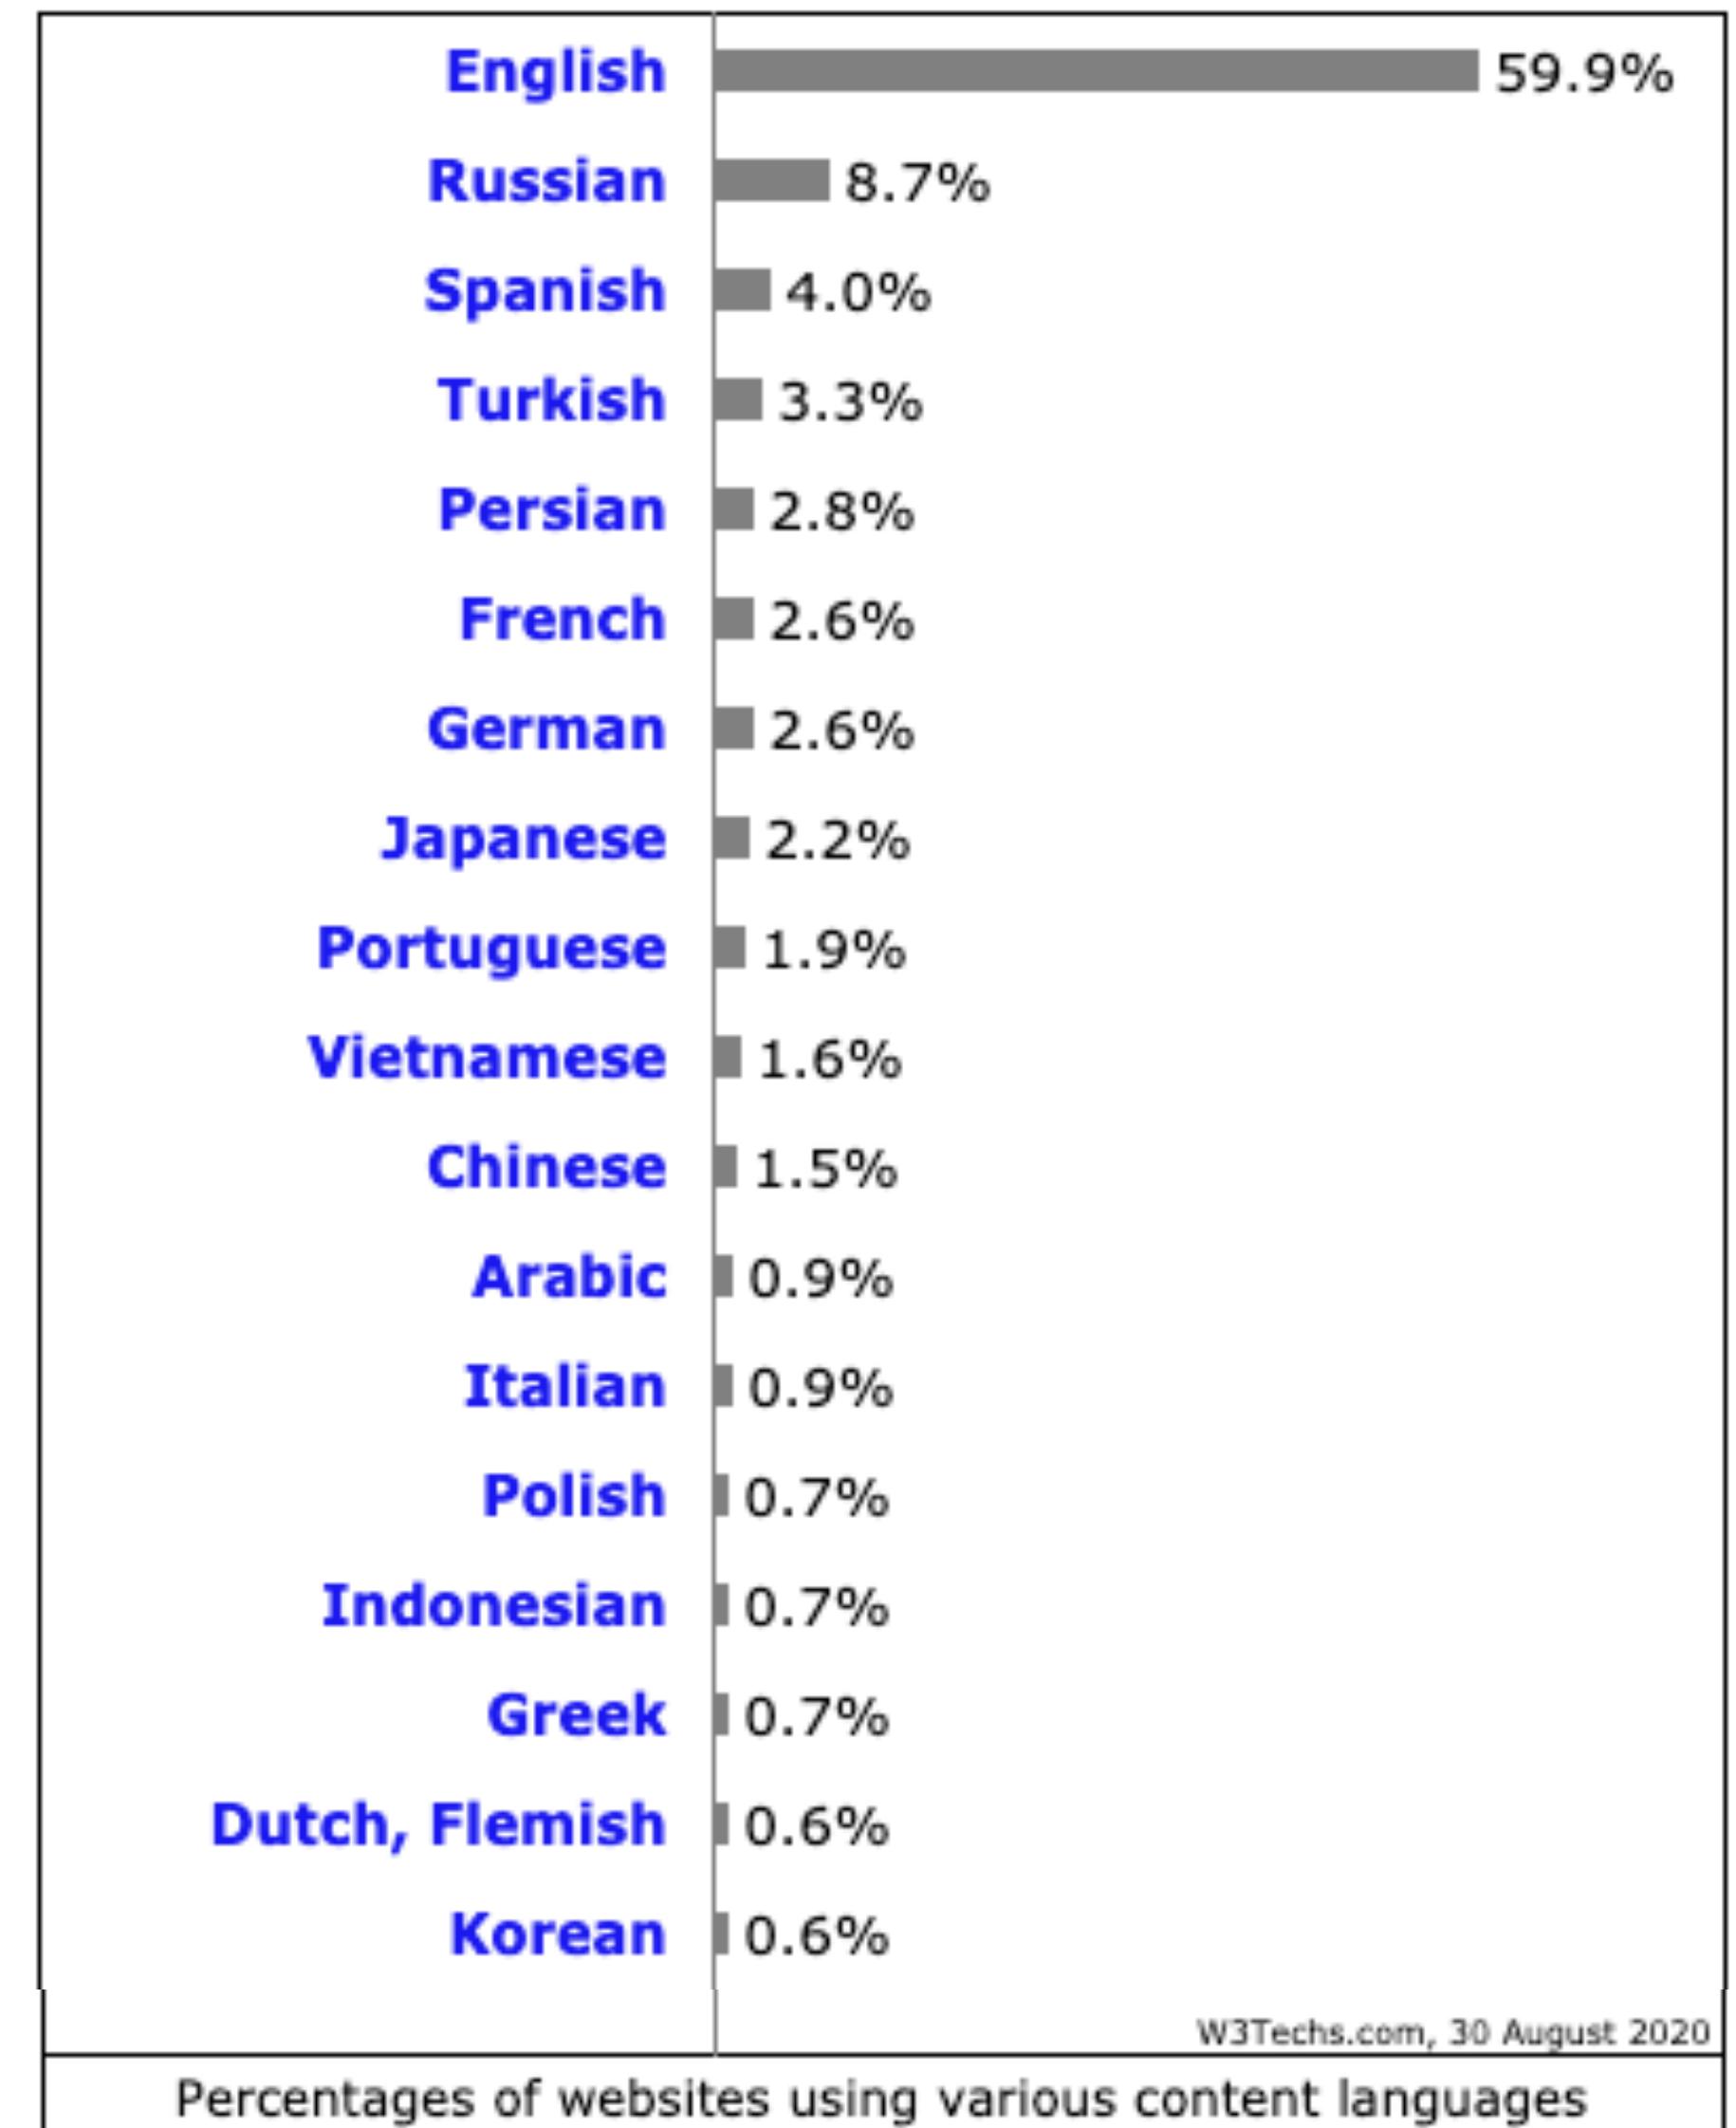
# 4차 산업혁명에서의 인재상은?



Required Skills: Programming


Preferred Skills: ?

# 영어를 모른다는 것은?





# 코딩을 할 줄 모른다?






# 강의계획

- 1주차
  - 환경설정, Github, Slack 사용법
- 2주차
  - Python 변수, 기본 연산, 출력
- 3주차
  - Python 문자열
- 4주차
  - 조건문, 반복문
- 5주차
  - 함수
- 6주차
  - 클래스 I
- 7주차
  - 클래스 II
- 8주차
  - 데이터 전처리
- 9주차
  - 데이터 시각화
- 10주차
  - 빅데이터 분석

# 프로그램 실행과정



# Python

- Guido van Rossum이 1991년에 최초 배포
- 코드의 가독성을 높이는 것이 파이썬의 철학
- 언어 특징
  - Interpreted
  - High Level
  - General Purpose



# Python을 이용해서

- Logic을 만들 수 있어야 하며
  - 간단한 if-else
  - 자료구조/알고리즘
  - 수학적 연산
  - 모델 정의
- 데이터/파일을 Read/Write 할 수 있어야 한다.
  - 로컬 파일 읽기
  - 외부 파일 (e.g., 클라우드, 웹사이트) 읽기
  - 데이터 변형
  - 모델 저장



# 머신러닝 (Machine Learning)

- 머신러닝 : 데이터 + 알고리즘
  - 기존에 단순 rule-base 또는 통계 기반으로 해결하지 못한 문제를 데이터의 힘을 빌려 해결한다.
- Python 기반의 라이브러리들을 활용
  - Numpy, Pandas, Matplotlib, Scikit Learn
  - Tensorflow, Pytorch

# 빅데이터

## 얼마나 커야 “빅” 데이터인가?



2000년  
HDD: 20GB  
RAM: 64MB



2020년  
SSD: 512GB  
RAM: 16GB

# 빅데이터

- 저장소의 용량은 기하급수적으로 증가하는 반면 처리량은 선형적으로 증가
  - 하드 드라이브에 있는 데이터를 모두 처리하는데 걸리는 시간은 매년 증가
  - SSD의 개발로 더 복잡한 데이터 처리에 더 복잡한 알고리즘과 프레임워크를 사용할 수 있게 되었지만, 아래와 같은 동향은 변하지 않음 (Wiktorski, 2019)




Fig. 2.2 Historical capacity versus throughput for HDDs. Source Leventhal (2009)

# 빅데이터

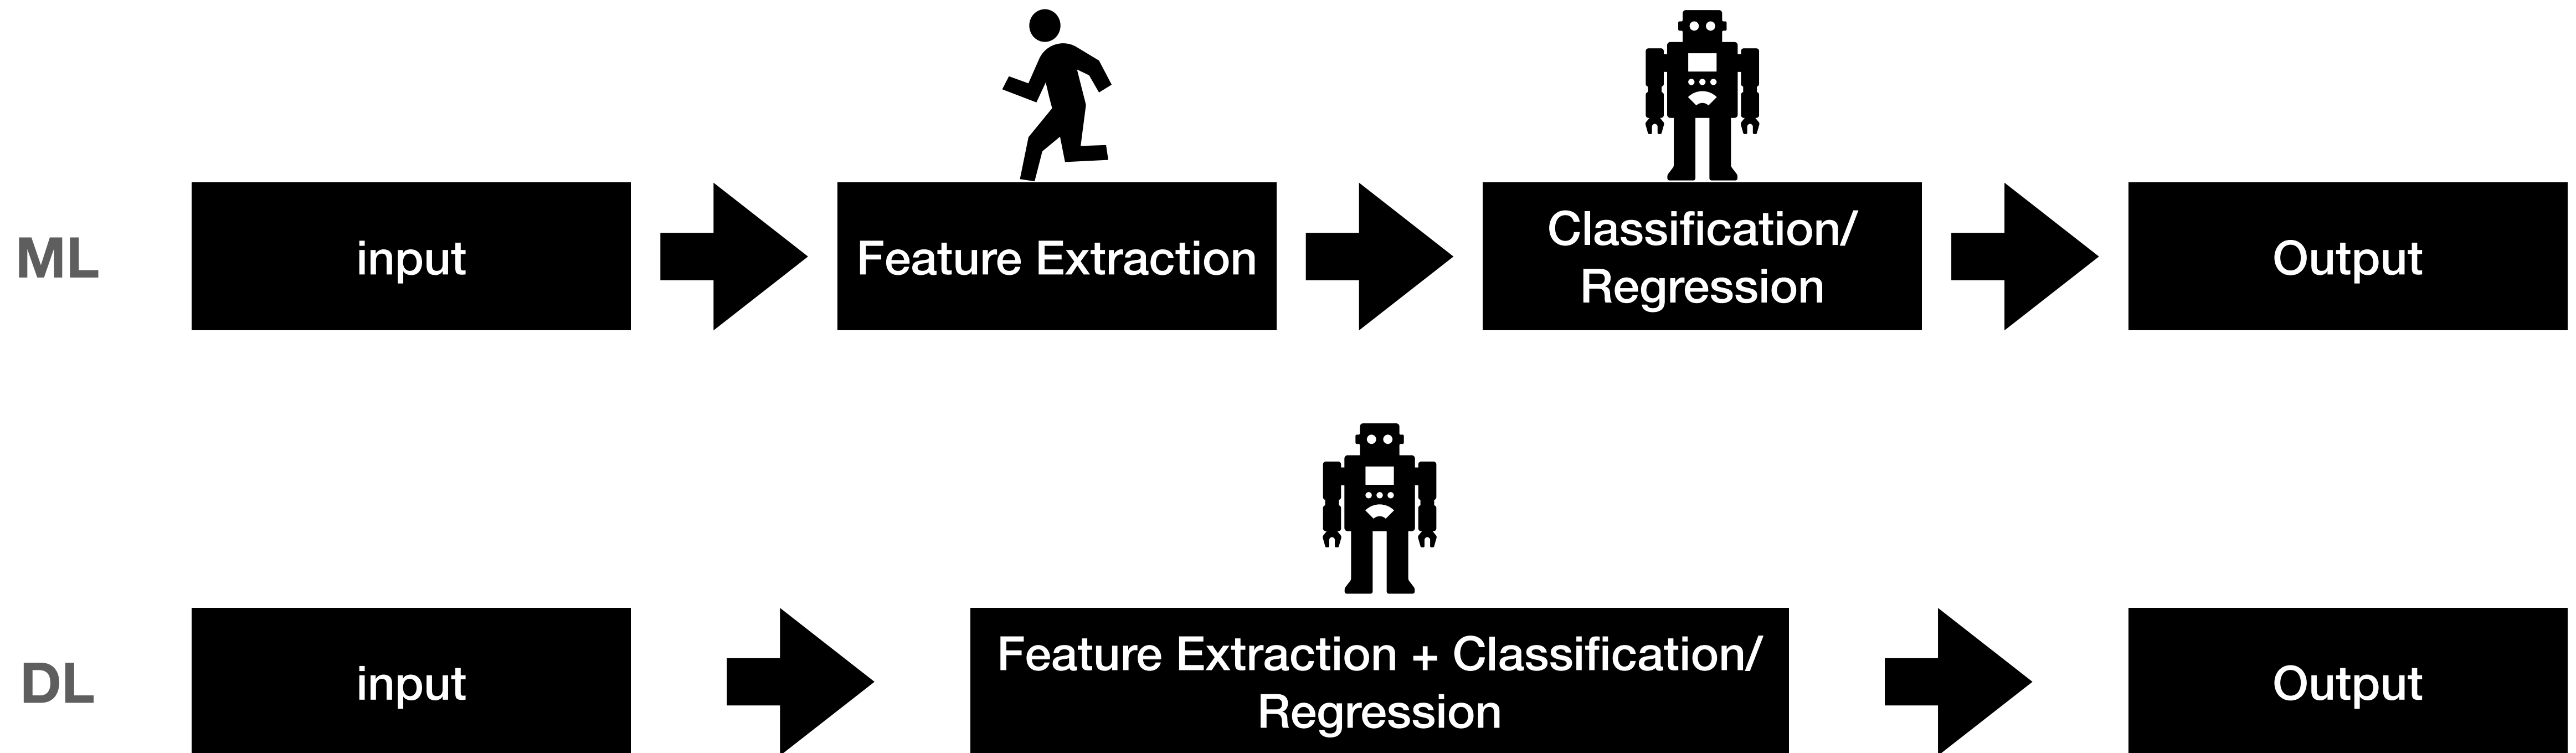
- 어떻게 많은 양의 데이터를 효과적으로 저장/처리/분석 할 수 있을까?
- 분산 컴퓨팅
  - Hadoop, Spark





# 딥러닝

딥러닝과 머신러닝의 차이는?




# 배울 내용들

- 지식적인 측면
  - Python 프로그래밍에 익숙해지기
  - 데이터 핸들링 익숙해지기
- 실무적인 측면
  - Github 활용법
  - Shell 활용법

# 성적평가

- 1시간 이론강의, 2시간 실습강의
- 매 수업 퀴즈
  - 성적평가 미반영 (점검용)
- 참여도 (40%)
  - 출석 + Q&A 답변
- 과제 (60%)
  - 매주 작은 과제

# 수업 목표





**E.O.D**